

Kap. Einfache lineare Regression

Geg. Stichprobe $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ quantitative Daten

Bsp. $x_1 = 64 [\%]$ $y_1 = 2.5$ Bsp. UN-Daten Algerien

Empirische(r) Korrelation(koeffizient) nach Pearson

$$r_{xy} := \frac{s_{xy}}{s_x \cdot s_y} \quad \text{mit} \quad s_{xy} := \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x}) \cdot (y_i - \bar{y})$$

Wdh.

$$s_x^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$
$$s_x = \sqrt{s_x^2}$$

s_{xy} : empirische Kovarianz

$$s_{xy} = \frac{1}{n-1} \left(\sum_{i=1}^n x_i \cdot y_i - n \bar{x} \cdot \bar{y} \right)$$

Es gilt: 1) Bei linearer Transformation der Daten

$$\begin{array}{l} x_1, \dots, x_n \quad \text{d.h.} \quad x_i \mapsto a \cdot x_i + b \quad (\text{z.B. } ^\circ\text{C} \rightarrow ^\circ\text{F}, a = \frac{9}{5}, b = 32) \\ y_1, \dots, y_n \quad y_i \mapsto c \cdot y_i + d, \quad \underline{a \neq 0, c \neq 0} \end{array}$$

$$|r_{ax+b, cy+d}| = |r_{xy}|$$

2) $-1 \leq r_{xy} \leq 1$

3) $|r_{xy}| = 1 \Leftrightarrow$ Alle Punkte $(x_1, y_1), \dots, (x_n, y_n)$ liegen auf dieselben Geraden, d.h. $y_i = a \cdot x_i + b$ für alle $i = 1, 2, \dots, n$

Bsp. UN-Daten

$$s_{xy} = \frac{1}{35-1} (64 \cdot 2,5 + \dots + 21 \cdot 6,2 - 35 \cdot 65,2 \cdot 2,35)$$
$$\bar{x} = \frac{64 + \dots + 21}{35} \approx 65,2 \quad \bar{y} = \frac{2,5 + \dots + 6,2}{35} \approx 2,39$$

$$s_x^2 = \frac{1}{35-1} (64^2 + \dots + 21^2 - 35 \cdot 65,2^2) \approx 336,75$$

$$s_y^2 = \frac{1}{35-1} (2,5^2 + \dots + 6,2^2 - 35 \cdot 2,39^2) \approx 1,40$$

$$r_{xy} = \frac{s_{xy}}{s_x \cdot s_y} \approx \frac{-19,11}{\sqrt{336,75} \cdot \sqrt{1,40}} \approx -0,879 \quad \text{negative Korrelation}$$

Einfache lineare Regression: Regressionsgerade